

LÖSNINGAR TILL

Matematisk statistik,
Matematikcentrum
Lunds tekniska högskola
Lunds universitet

Tentamen: 2003-05-28 kl 8⁰⁰-13⁰⁰
FMS 012, Matematisk statistik för F, 6 p
FMS 022, Matematisk statistik för EDC, 6 p
FMS 121, Matematisk statistik för I, 6 p
MAS 233, Matematisk statistik för fysiker, 6 p

1. (a) Med hjälp av komplementsatsen och Bayes sats fås den sökta sannolikheten till

$$P(B^* | A) = 1 - P(B | A) = 1 - \frac{P(A | B)P(B)}{P(A)} = 1 - \frac{0.7 \cdot 0.4}{0.3} = \frac{1}{15}$$

- (b) X och Y är oberoende och likafördelade.

$$\begin{aligned} P(\min(X, Y) \leq 1) &= 1 - P(\min(X, Y) > 1) = 1 - P(X > 1, Y > 1) = [\text{oberoende}] = \\ &= 1 - P(X > 1)P(Y > 1) = 1 - [1 - F_X(1)][1 - F_Y(1)] = \\ &= 1 - [1 - (1 - e^{-1^2})]^2 = 1 - (e^{-1^2})^2 = 1 - e^{-2} \end{aligned}$$

- (c) Låt X = "Antal rätta svar", då är $X \in \text{Bin}(19, 0.25)$ och sannolikheten att bli godkänd blir

$$\begin{aligned} P(X \geq 10) &= 1 - P(X \leq 9) = 1 - F_X(9) = [\text{Tabell 8: } n = 19, p = 0.25, x = 9] = \\ &= 1 - 0.99110 = 0.0089 \end{aligned}$$

- (d) Låt X_i = "mängd bål person nr. i dricker", $X_i \in N(3, 1.5)$. Den totala mängden bål som 15 personer dricker blir då

$$Y = \sum_{i=1}^{15} X_i$$

För Y har vi $Y \in N(3 \cdot 15, 1.5 \cdot \sqrt{15})$. Sannolikheten att 5 liter bål räcker till festen blir

$$P(Y \leq 50) = \Phi\left(\frac{50 - 45}{1.5\sqrt{15}}\right) \approx \Phi(0.86) \approx 0.81$$

2. (a) För att få reda på sannolikheten att kedjan är i tillsånd E_0 tre steg efter start i E_0 kan vi räkna ut element $(1, 1)$ övergångsmatrisen av tredje ordningen, P^3 . Vi kan t.ex först räkna ut första radens element i P^2 (de element som inte behövs har ersatts med -).

$$\begin{aligned} P^2 &= P \cdot P = \begin{pmatrix} 0 & 2/3 & 1/3 \\ - & - & - \\ - & - & - \end{pmatrix} \begin{pmatrix} 0 & 2/3 & 1/3 \\ 1/2 & 0 & 1/2 \\ 1/4 & 3/4 & 0 \end{pmatrix} = \begin{pmatrix} 5/12 & 3/12 & 1/3 \\ - & - & - \\ - & - & - \end{pmatrix} \\ P^3 &= P^2 \cdot P = \begin{pmatrix} 5/12 & 3/12 & 1/3 \\ - & - & - \\ - & - & - \end{pmatrix} \begin{pmatrix} 0 & 2/3 & 1/3 \\ 1/2 & 0 & 1/2 \\ 1/4 & 3/4 & 0 \end{pmatrix} = \begin{pmatrix} 5/24 & - & - \\ - & - & - \\ - & - & - \end{pmatrix} \end{aligned}$$

Alternativt kan man se att det bara finns två möjligheter att ta sig från E_0 till E_0 i tre steg, $E_0 \rightarrow E_1 \rightarrow E_2 \rightarrow E_0$ eller $E_0 \rightarrow E_2 \rightarrow E_1 \rightarrow E_0$. Sannolikheten för detta blir då

$$p_{00}^{(3)} = \frac{2}{3} \cdot \frac{1}{2} \cdot \frac{1}{4} + \frac{1}{3} \cdot \frac{3}{4} \cdot \frac{1}{2} = \frac{5}{24}$$

- (b) Kedjans stationära fördelning ges av lösningen till ekvationssystemet $\pi P = \pi$ tillsammans med bilvillkoret $\sum \pi_i = 1$.

$$\pi P = (\pi_1, \pi_2, \pi_3) \begin{pmatrix} 0 & 2/3 & 1/3 \\ 1/2 & 0 & 1/2 \\ 1/4 & 3/4 & 0 \end{pmatrix} = \left(\frac{\pi_2}{2} + \frac{\pi_3}{4}, \frac{2\pi_1}{3} + \frac{3\pi_3}{4}, \frac{\pi_1}{3} + \frac{\pi_2}{2}\right) = (\pi_1, \pi_2, \pi_3)$$

Två av dessa ekvationer tillsammans med bivillkoret ger lösningen $\pi = (\frac{15}{53}, \frac{22}{53}, \frac{16}{53})$.

3. Man söker sannolikheten att hållfastheten är större än belastningen, dvs

$$P(X > Y) = \text{sannolikheten att hamna i området } x > y, x > 0, 1 < y < 2.$$

Sannolikheten ges av att man integrerar den tvådimensionella täthetsfunktionen över området. Eftersom X och Y är oberoende är den integranden

$$f_{X,Y}(x,y) = f_X(x)f_Y(y) = \frac{1}{5}e^{-x/5} \cdot 1, \quad x > 0, 1 < y < 2.$$

Alltså

$$\begin{aligned} P(X > Y) &= \int_1^2 \int_y^\infty \frac{1}{5}e^{-x/5} dx dy = \int_1^2 [-e^{-x/5}]_y^\infty dy = \\ &= \int_1^2 0 + e^{-y/5} dy = [-5e^{-y/5}]_1^2 = 5(e^{-1/5} - e^{-2/5}) = 0.7417. \end{aligned}$$

4. Den enda rimliga modellen baserad på normalfördelade observationer med lika varians är att vi har oberoende observationer för de gamla respektive nya hönornas äggvikter enligt

$$x_i \text{ observation av } X_i \in N(m_X, \sigma), \quad i = 1, \dots, n$$

$$y_i \text{ observation av } Y_i \in N(m_Y, \sigma), \quad i = 1, \dots, n$$

där $n = 15$. För att ta reda på om det är någon signifikant skillnad i äggvikterna för de olika typerna av höns kan vi testa hypotesen

$$\begin{aligned} H_0 : m_X = m_Y &\iff H_0 : m_X - m_Y = 0 \\ H_1 : m_X \neq m_Y &\iff H_1 : m_X - m_Y \neq 0 \end{aligned}$$

För att testa hypotesen på nivå $\alpha = 0.05$ kan vi t.ex göra ett 95% konfidensintervall för $m_X - m_Y$ och förkasta H_0 om detta intervall inte täcker punkten noll. Medelvärden och stickprovsvarianser för de två dataserierna blir

$$\begin{aligned} \bar{x} &= \frac{797.8}{15} = 53.19, \quad \bar{y} = \frac{839.7}{15} = 55.98 \\ s_x^2 &= \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2 = \frac{1}{n-1} \left(\sum_{i=1}^n x_i^2 - \frac{1}{n} \left(\sum_{i=1}^n x_i \right)^2 \right) = \frac{1}{14} \left(42\,559 - \frac{1}{15} \cdot 797.8^2 \right) = \\ &= 9.0612 \\ s_y^2 &= \frac{1}{n-1} \sum_{i=1}^n (y_i - \bar{y})^2 = \frac{1}{14} \left(47\,103 - \frac{1}{15} \cdot 839.7^2 \right) = 6.8874 \end{aligned}$$

Med hjälp av detta kan vi skatta skillnaden med

$$m_X^* - m_Y^* = \bar{x} - \bar{y} = -2.79 \text{ som är en observation av } m_X^* - m_Y^* \in N \left(m_X - m_Y, \sigma \sqrt{\frac{1}{n} + \frac{1}{n}} \right)$$

och den gemensamma standardavvikelsen skattas med

$$s = \sqrt{\frac{(n-1)s_x^2 + (n-1)s_y^2}{n-1+n-1}} = \sqrt{\frac{14 \cdot 9.0612 + 14 \cdot 6.8874}{28}} = 2.824$$

Konfidensintervallet fås till

$$\begin{aligned} I_{m_X - m_Y} &= m_X^* - m_Y^* \pm t_{\alpha/2}(n-1) d(m_X^* - m_Y^*) = \bar{x} - \bar{y} \pm t_{0.025}(28) s \sqrt{\frac{1}{n} + \frac{1}{n}} = \\ &= -2.79 \pm 2.05 \cdot 2.824 \cdot \sqrt{\frac{2}{15}} = [-4.90, -0.67] \end{aligned}$$

Intervallet täcker inte punkten noll så H_0 kan förkastas på nivå 0.05. Det är alltså signifikant skillnad mellan vikterna.

Observera att vi inte på något vis har parvisa observationer, så en modell baserad på ”stickprov i par” kan inte användas oavsett vilket av de 1 307 674 368 000 möjliga sätten att para ihop x_i med y_i man väljer.

5. (a) Skattningar av parametrarna ges av

$$\begin{aligned} \theta^* &= \begin{bmatrix} \alpha^* \\ \beta_1^* \\ \beta_2^* \end{bmatrix} = (U^T U)^{-1} \cdot U^T Y = 10^{-4} \begin{bmatrix} 100 & 0 & 0 \\ 0 & 0.5585 & 0.8779 \\ 0 & 0.8779 & 106.7 \end{bmatrix} \cdot 10^4 \begin{bmatrix} 2.149 \\ 0.8449 \\ -0.06512 \end{bmatrix} = \begin{bmatrix} 214.91 \\ 0.41466 \\ -6.2102 \end{bmatrix} \\ \sigma^* &= \sqrt{\frac{Q_0}{n-3}} = \sqrt{\frac{40\,232}{97}} \approx 20.3658 \end{aligned}$$

- (b) För att testa om vikten har någon signifikant inverkan på kolesterolhalten kan vi testa

$$H_0 : \beta_1 = 0$$

$$H_1 : \beta_1 \neq 0$$

på nivån 0.05. Testet kan t.ex. utföras genom att förkasta H_0 om $|u| > t_{0.05/2}(97)$, där

$$u = \frac{\beta_1^* - 0}{d(\beta_1^*)}$$

För att få fram $d(\beta_1^*)$ får vi titta i kovariansmatrisen

$$V(\theta^*) = \sigma^2 (U^T U)^{-1} = \begin{bmatrix} V(\alpha^*) & C(\beta_1^*, \alpha^*) & C(\beta_2^*, \alpha^*) \\ C(\alpha^*, \beta_1^*) & V(\beta_1^*) & C(\beta_2^*, \beta_1^*) \\ C(\alpha^*, \beta_2^*) & C(\beta_1^*, \beta_2^*) & V(\beta_2^*) \end{bmatrix}$$

En skattning av denna fås genom att stoppa in en skattning av σ^2

$$V(\theta^*)^* = (\sigma^2)^* \cdot (U^T U)^{-1} = \begin{bmatrix} 4.1477 & 0 & 0 \\ 0 & 0.02316 & 0.03641 \\ 0 & 0.03641 & 4.4273 \end{bmatrix}$$

Andra diagonalelementet i denna matris är alltså en skattning av $V(\beta_1^*)$ så vi får

$$u = \frac{\beta_1^* - 0}{d(\beta_1^*)} = \frac{0.4147}{\sqrt{0.023163}} = 2.7245$$

$t_{0.025}(97)$ står inte utsatt i tabell 3, men vi ser att den måste ligga någonstans mellan 1.98 och 2.00, så vi kan således förkasta H_0 på nivå 0.05 och konstatera att även vikten har en signifikant inverkan på kolesterolhalten.

- (c) För personer som väger $x_1 = 82$ kg och tränar $x_2 = 1$ gång per vecka kan vi skatta väntevärdet av kolesterolhalten med

$$\begin{aligned} m_0^* &= \alpha^* + \beta_1^*(82 - \bar{x}_1) + \beta_2^*(1 - \bar{x}_2) = \\ &= 214.91 + 0.41466 \cdot (82 - 68.05) - 6.2102 \cdot (1 - 0.97) \approx 220.51 \end{aligned}$$

Varians och medelfel för denna skattning blir (observera att β_1^* och β_2^* ej är okorrelerade)

$$\begin{aligned} V(m_0^*) &= V(\alpha^*) + V(\beta_1^*)(82 - \bar{x}_1)^2 + V(\beta_2^*)(1 - \bar{x}_2)^2 + 2(82 - \bar{x}_1)(1 - \bar{x}_2)C(\beta_1^*, \beta_2^*) \\ d(m_0^*) &= \sqrt{4.1477 + 0.02316(82 - \bar{x}_1)^2 + 4.4273(1 - \bar{x}_2)^2 + 2(82 - \bar{x}_1)(1 - \bar{x}_2)0.03641} = \\ &\approx 2.9476 \end{aligned}$$

Ett 95% konfidensintervall för den förväntade kolesterolhalten m_0 blir

$$I_{m_0} = m_0^* \pm t_{0.025}(97)d(m_0^*) = 220.51 \pm 2.00 \cdot 2.9476 \approx [214.6, 226.4]$$

6. (a) Maximum-likelihood-skattningen av p ges av det p som maximerar (log-) Likelihood-funktionen. Denna är produkten av sannolikhetsfunktionerna där vi sätter in *observationerna* $x_1, \dots, x_n$ i var och en.

$$L(p) = \prod_{i=1}^n p_X(x_i) = p(1-p)^{x_1-1} \cdot \dots \cdot p(1-p)^{x_n-1} = p^n(1-p)^{\sum_{i=1}^n (x_i-1)}$$

$$\ln L(p) = n \ln p + \ln(1-p) \sum_{i=1}^n (x_i - 1)$$

$$\frac{d \ln L(p)}{dp} = \frac{n}{p} - \frac{1}{1-p} \sum_{i=1}^n (x_i - 1) = 0 \implies$$

$$n(1-p) = p \sum_{i=1}^n (x_i - 1) = p \sum_{i=1}^n x_i - np \implies$$

$$p = \frac{n}{\sum_{i=1}^n x_i} = \frac{1}{\frac{1}{n} \sum_{i=1}^n x_i} = \frac{1}{\bar{x}}$$

Detta värde på p maximerar $L(p)$ så ML-skattningen blir $p^* = 1/\bar{x}$.

- (b) Nu är p^* , betraktad som stokastisk variabel, en olinjär funktion av de n oberoende variablerna $X_1, \dots, X_n$, där $E(X_i) = 1/p$ och $V(X_i) = (1-p)/p^2$ enligt formelsamlingen. Eftersom $\bar{X}$ är en linjär funktion kan vi beräkna väntevärde och varians för $\bar{X}$ exakt och betrakta p^* som en funktion av en variabel $\bar{X}$.

$$E(\bar{X}) = E\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n} \sum_{i=1}^n E(X_i) = \frac{1}{n} \sum_{i=1}^n \frac{1}{p} = \frac{1}{n} \cdot n \cdot \frac{1}{p} = \frac{1}{p}$$

$$V(\bar{X}) = V\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n^2} \sum_{i=1}^n V(X_i) = \frac{1}{n^2} \sum_{i=1}^n \frac{1-p}{p^2} = \frac{1}{n^2} \cdot n \cdot \frac{1-p}{p^2} = \frac{1-p}{np^2}$$

Med $p^* = g(\bar{X}) = 1/\bar{X}$ fås med Gauss approximationsformler

$$E(p^*) = E(g(\bar{X})) \approx g(E(\bar{X})) = \frac{1}{E(\bar{X})} = \frac{1}{1/p} = p$$

$$\begin{aligned} V(p^*) &= V(g(\bar{X})) \approx g'(E(\bar{X}))^2 V(\bar{X}) = \left(-\frac{1}{E(\bar{X})^2}\right)^2 V(\bar{X}) = \left(-\frac{1}{1/p^2}\right)^2 \frac{1-p}{np^2} = \\ &= \frac{p^2(1-p)}{n} \end{aligned}$$